

Kaggle Contest - 1조

2023.05.30

발표자 : 김예원

스터디원 소개 및 만남 인증



응용통계학과 19 정서현

전자전기공학부 19 성현우

AI학과 21 김예원

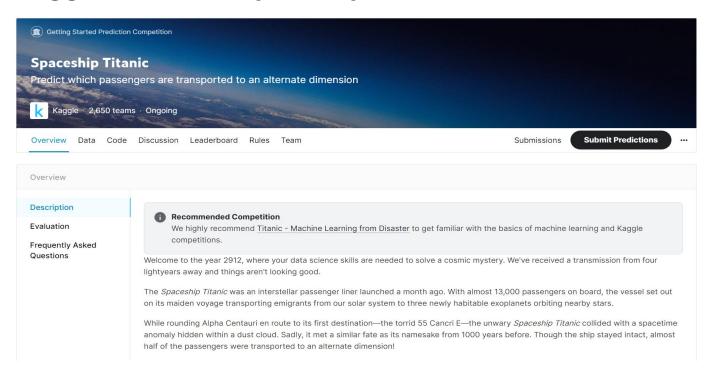
AI학과 21 김건호

에너지시스템공학부 16 김지호

목차

- 1. Kaggle Contest 소개
- 2. Data 소개
- 3. Data 전처리
- 4. Feature Selection
- 5. 모델 소개

Kaggle Contest - Spaceship Titanic



타이타닉호가 시공간 이상과 충돌하는 동안 승객이 다른 차원으로 이송되었는지를 예측

평가기준 : Accuracy

Data

	Passengerld	HomePlanet	CryoSleep	Cabin	Destination	Age	VIP
0	0001_01	Europa	False	B/0/P	TRAPPIST- 1e	39.0	False
1	0002_01	Earth	False	F/0/S	TRAPPIST- 1e	24.0	False
2	0003_01	Europa	False	A/0/S	TRAPPIST- 1e	58.0	True
3	0003_02	Europa	False	A/0/S	TRAPPIST- 1e	33.0	False
4	0004_01	Earth	False	F/1/S	TRAPPIST- 1e	16.0	False

RoomService	FoodCourt	ShoppingMall	Spa	VRDeck	Name	Transported
0.0	0.0	0.0	0.0	0.0	Maham Ofracculy	False
109.0	9.0	25.0	549.0	44.0	Juanna Vines	True
43.0	3576.0	0.0	6715.0	49.0	Altark Susent	False
0.0	1283.0	371.0	3329.0	193.0	Solam Susent	False
303.0	70.0	151.0	565.0	2.0	Willy Santantines	True

Passengerld : 승객 ID

HomePlanet : 출발 행성(거주지)

· CryoSleep : 취침 방식 여부

• Cabin : 객실 종류 및 번호 (port : 좌현, starboard : 우현)

• Destination : 목적지

Age : 승객의 나이

• **VIP**: 승객의 VIP 서비스 유무

 RoomService, FoodCourt, ShoppingMall, Spa, VRDeck : 승객이 해당 서비스에 대해 지불한 금액

• Name : 이름

Transported : 도착 여부 예측해야하는 target

Data 전처리

train.is	null().sum	()
_		

Passengerld	0
HomePlanet	201
CryoSleep	217
Cabin	199
Destination	182
Age	179
VIP	203
RoomService	181
FoodCourt	183
ShoppingMall	208
Spa	183
YRDeck	188
Name	200
Transported	0

'Passengerld'와 'Transported'(target)를 제외한 사실상 모든 피쳐에 결측치가 존재했음.

결측치가 있는 <mark>모든 행을 drop</mark>하면 전체 데이터의 24%가 제거됨.

```
train.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8693 entries 0 to 8692

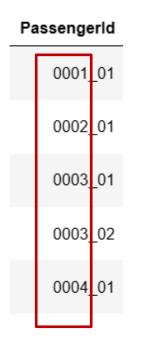
train.dropna().info()

<class 'pandas core frame DataFrame'>
Int64Index: 6606 entries, 0 to 8692
Data columns (total 14 columns):
```

약 2주간 결측치를 제거하지 않고 피쳐 간 상관관계를 파악해 결측치를 처리하고자 했음.

Data 전처리

- 1. 결측치 처리에서의 **Key Point :** Passengerld 앞 번호를 이용해 **group칼럼**을 생성 -> **group과 피쳐간 상관성**을 파악하는 것이었음.
- 2. Name 피쳐는 미리 삭제함.





Data 전처리 - HomePlanet

HomePlanet CryoSleep Cabin Destination Age VIP RoomService FoodCourt ShoppingMall Spa VRDeck Name Transported

	Number_missing	Percentage_missing
HomePlanet	201	2.31
CryoSleep	217	2.50

201개의 NaN 값 (2.31%)

- 1. PassengerID는 0000_00 꼴인데 앞의 4자리가 같으면 일행이다. 즉, 같은 행성 출신이다.
- 2. Name 피쳐로부터 서로 같은 성씨(Last name)인 경우에는 같은 행성 출신이다.

-> 이 두 가지 사실을 이용하여 결측치 처리

HomePlanet 컬럼이 결측치인 승객 중, 그룹 내에서 다른 HomePlanet이 적어도 하나 존재하는 그룹의 경우 해당그룹의 존재하는 승객의 고향을 따오는 과정

```
In [13]: | # Missing values before
             HP bef=data['HomePlanet'].isna().sum() # HomePlanet0/ 결측치인 갯수
             # Passengers with missing HomePlanet and in a group with known HomePlanet
             GHP_index=data[data['HomePlanet'].isna()][(data[data['HomePlanet'].isna()]['Group']).isin(GHP_db.index)].index #HomePlanet 필터이 골트
             # Fill corresponding missing values
             data.loc[GHP_index, 'HomePlanet']=data.iloc[GHP_index,:]['Group'].map(lambda x: GHP_gb.idxmax(axis=1)[x])
             # Print number of missing values left
             print('#HomePlanet missing values before:'.HP bef)
             print('#HomePlanet missing values after:'.data['HomePlanet'].isna().sum())
             #HomePlanet missing values before: 201
             #HomePlanet missing values after: 111
```

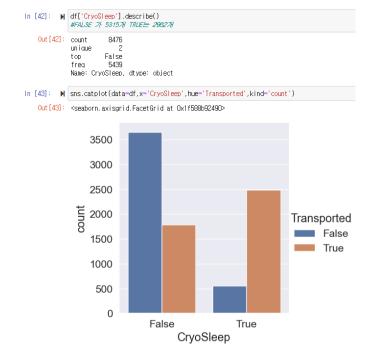
결측치가 111개로 줄어듬!

남은 HomePlanet 컬럼이 결측치인 승객 중, 그룹 내에서 Surname이 같을 경우에 해당그룹에 존재하는 승객의 고향을 따오는 과정

```
In [14]: M # Joint distribution of Surname and HomePlanet
             SHP_gb=data,groupby(['Surname','HomePlanet'])['HomePlanet'].size(),unstack(),fillna(0)
             # Countriot of unique values
             plt.figure(figsize=(10,4))
             sns.countplot((SHP gb>0).sum(axis=1))
             plt.title('Number of unique planets per surname')
    Out [14]: Text(0.5, 1.0, 'Number of unique planets per surname')
```

CryoSleep: 217개의 NaN 값 (2.50%)¶

-> 'CryoSleep' True/False로 구분된 논리형(Boolean) 변수



- 결측값을 제외한 나머지 값 중 True는 2962개(약 35.8%), False는 5315개(약 64.2%)를 차지함.
- False 값이 약 1.8배정도 더 많이 차지함.
- 만약 결측값을 모두 False로 보관할 경우 차지하는 비율은 True(34.9%), False(65.1%) 로 1% 미만 범위에서 변함.
- 따라서 1% 미만의 변화는 유의미하지 않다는 가정하에 'CryoSleep'에서 결측된 값은 False로 보관함.

Data 전처리 - Cabin

HomePlanet CryoSleep

Cabin Destination Age VIP RoomService FoodCourt ShoppingMall

Spa VRDeck

Name Transported

Deck / number / side 호실 유형 / 호실 번호 / 호실 위치

\sim	-	h	i	,	
·	а	IJ	ı	ı	l

E	3/0/F)

F/0/S

A/0/S

A/0/S

F/1/S

Cabin_deck	Cabin_number	Cabin_side
В	0.0	Р
F	0.0	S
А	0.0	S
А	0.0	S
F	1.0	S

Data 전처리 - Cabin

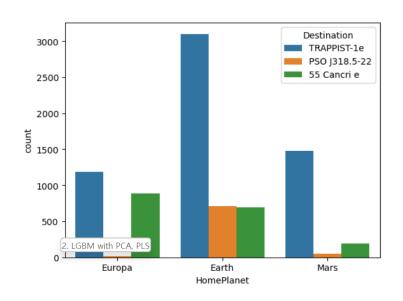
HomePlanet CryoSleep Cabin Destination Age VIP RoomService FoodCourt ShoppingMall Spa VRDeck Name Transported

```
In [16]: g_cs = pd.DataFrame(train_gs.groupby(['group'])['Cabin_side'].value_counts())
      g_cs.columns = ['count']
      g_cs = g_cs.reset_index()
      g cs
Out[16]:
           group Cabin_side count
                                                              sum(g_cd.duplicated('group'))
                                                              sum(g_cn.duplicated('group'))
            9252
                                              442/441개가 같은 group이어도
            9272
                                              같은 Cabin deck/number 값을 가지지 않았음.
            9275
           9280
                                              하지만 최빈값 처리보다 오류가 훨씬 적으므로 이 값을 이용.
       1412 rows × 3 columns
In [17]: sum(g_cs.duplicated('group'))
Out[17]
```

- -> 같은 group이면 모두 같은 Cabin_side 값을 가짐.
- -> Cabin side 결측치 199개를 모두 옳은 값으로 채울 수 있다.

Data 전처리 - Destination

HomePlanet CryoSleep Cabin Destination Age VIP RoomService FoodCourt ShoppingMall Spa VRDeck Name Transported



각각의 HomePlanet에서 온 승객들이 Destination 피쳐의 최빈값에 도착한 것을 알 수 있음.

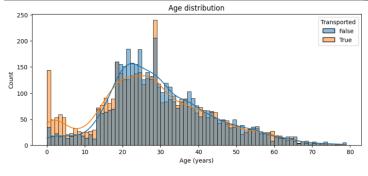
-> Destination의 최빈값으로 결측치 채우기.

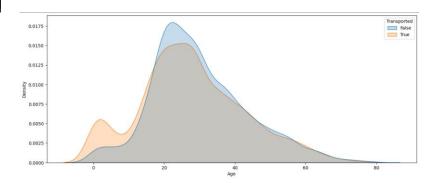
Data 전처리 – Age

HomePlanet CryoSleep Cabin Destination Age VIP RoomService FoodCourt ShoppingMall Spa VRDeck Name Transported



Age 결측치는 평균값으로 대체





- 20세 미만의 어린이나 아기들이 Trasnported한 경우가 더 많다.
- 20세에서 40세 사이에서는 Trasnported 되지 않은 사람이 조금 더 많다.
- 40대 이상에서는 Trasnported 한 사람과 하지 않은 사람이 비슷하다.

Data 전처리 - VIP

HomePlanet CryoSleep Cabin Destination Age VIP RoomService FoodCourt ShoppingMall Spa VRDeck Name Transported

< 데이터프레임 VIP 결축치를 채우기 >

범주형 변수의 경우 최빈값으로 대체

[] df['VIP']=df['VIP'].fillna(df['VIP'].mode()[0])

[] data['VIP']=data['VIP'].fillna(data['VIP'].mode()[0])

sns.countplot(data=df, x='VIP', hue='Transported')

Transported False 4000 True 3000 2000 1000 False True VIP

Age 결측치는 최빈값으로 대체

VIP의 유무는 결과에 차이를 보여주지 않는다.

- VIP를 신청한 사람 중 제대로 도착을 한 인원의 비중이 약 38퍼센트, 신청하지 않은 사람 중 도착한 인원의 비중이 약 50퍼센트인 것을 확인할 수 있다.
- 그래프로 나타냈을 때 약 1.3배의 차이가 있지만 신청을 하지 않은 사람의 비중이 압도적으로 크므로 크게 영향이 있다고 보기는 어렵다.

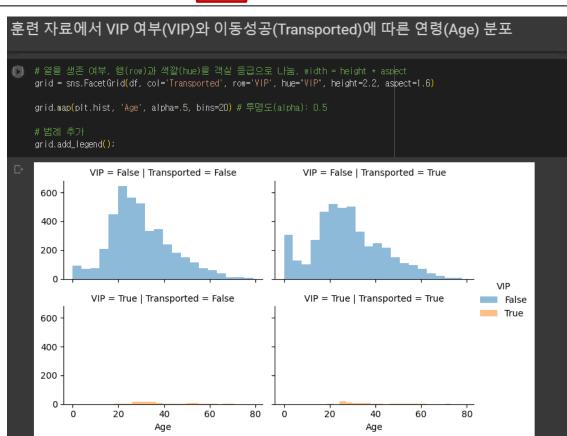
HomePlanet CryoSleep

Cabin Destination Age

VIP RoomService FoodCourt ShoppingMall

Spa VRDeck

Name Transported



HomePlanet CryoSleep

Cabin Destination Age

VIF

RoomService FoodCourt ShoppingMall

Spa VRDeck

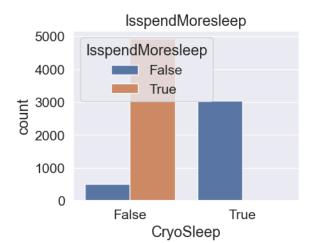
Name Transported

RoomService/FoodCourt/ShoppingMall/Spa/VRDeck 모두 승객의 소비에 관련된 것들이므로 모두 묶어 SPEND 피처를 생성

1. Cryo Sleep 과의 관계

데이터셋에 isspendmoresleep 피처생성 -> Spend항목 중 하나라도 존재하는 사람에 1 값 저장 -> Creo Sleep과의 관계파악 -> Spend 결측치 대체

#Expenditure missing values after: 582



```
# Missing values before
Nsp=df[spend].isna().sum().sum()

# CryoSleep has no expenditure
for col in spend:
    df.loc[(df[col].isna()) & (df['CryoSleep']==True), col]=0

# Print number of missing values left
print('#Expenditure missing values before:',Nsp)
print('#Expenditure missing values after:',df[spend].isna().sum())

#Expenditure missing values before: 943
```

HomePlanet CryoSleep

Cabin Destination Age

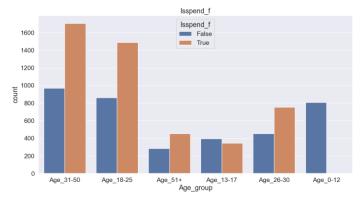
RoomService FoodCourt ShoppingMall

Spa VRDeck

Name Transported

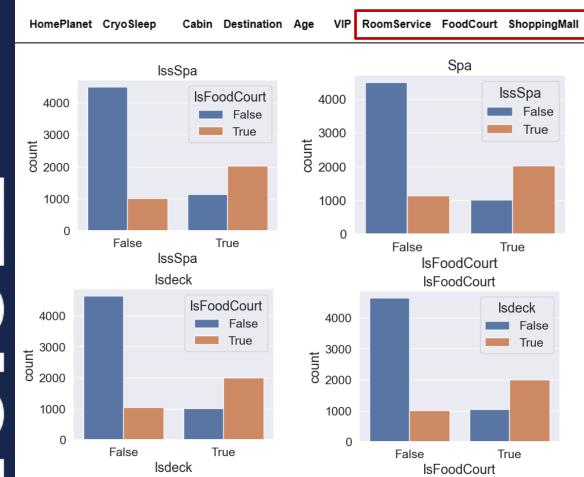
2. Age 와의 관계

Age정보 범주형으로 그룹화 - > Age 12세 이하 spend 항목 결측치 전원 0 처리



```
# Missing values before
Nsp=df[spend].isna().sum().sum()
# 0~12 has no expenditure
for col in spend:
   df.loc[(df[col].isna()) & (df['Age_group']=='Age_0-12'), col]=0
# Print number of missing values left
print('#Expenditure missing values before:',Nsp)
print('#Expenditure missing values after:',df[spend].isna().sum().sum())
```

#Expenditure missing values before: 582 #Expenditure missing values after: 537



동일한 SPEND 항목끼리의 존재여부로 Spend 내에서 관계 파악 -> 결측치 채우기.

Name Transported

Spa VRDeck

HomePlanet CryoSleep

Cabin Destination Age

VII

RoomService FoodCourt ShoppingMall

Spa VRDeck

Name Transported

Transported와의 음의 상관관계를 이용해 결측치를 채움.

직접적인 상관관계가 약한 Homplanet 에 따른 spend 항목의 평균값을 이용-> 남은 결측치를 채움.

Data 전처리 - 각각 전처리한 모든 칼럼 최종 병합

```
df1 = pd.read_csv("C:/Users/MSI/Desktop/CUAI/Basic/무주선 타이타닉_베이직/결측치 처리_05.18/Home,Cryo_성현무")
df2 = pd.read_csv("C:/Users/MSI/Desktop/CUAI/Basic/무주선 타이타닉_베이직/결측치 처리_05.18/Cabin,Dest_김예원")
df3 = pd.read_csv("C:/Users/MSI/Desktop/CUAI/Basic/무주선 타이타닉_베이직/결측치 처리_05.18/Age,VIP_정서현")
df4 = pd.read_csv("C:/Users/MSI/Desktop/CUAI/Basic/무주선 타이타닉_베이직/결측치 처리_05.18/Spend_김지호")
```

```
df = pd.concat([df1, df2, df3, df4],axis=1)
```

데이터 원 핫 인코딩

```
one_hot_df = pd.get_dummies(Age_train, columns=["HomePlanet", "CryoSleep", "Destination", "Cabin_deck", "Cabin_side", 'VIP'], drop_first=Tru
one_hot_df["Transported"].replace({True:1,False:0}, inplace=True)
```

Feature Selection

Passengerld와 Cabin_number(방 번호)는 Transported와 무관할 것으로 예상 -> 피처 선택 시 제외 실제로 Cabin_number 피처를 선택하지 않았을 경우 예측성능이 약 0.21 향상됨.

Passengerld	Cabin_number
0001_01	0
0002_01	0
0003_01	0
0003_02	0
0004_01	1

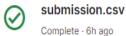
모델 소개 - SVC / LGBM / XGB / RF / KNN

5개의 모델을 정하고 각자 1개의 모델을 맡아 하이퍼파라미터 튜닝을 진행.

0	knn3_submission_csv.csv Complete · 3m ago	0.78349	\odot	submission2.csv Complete · 15s ago	0.7	8021	\otimes	submission.csv Complete · 2d ago	0.80313	
∅	knn2_submission_csv.csv Complete · 9m ago	0.78021	0	submission2.csv	0.7	0984	0	submission.csv	0.80056	
\otimes	knn_submission_csv.csv Complete · 14m ago	0.5768		submission1.csv			0	submission.csv	0.70000	
\otimes	X_cabin_number_gbc_submission_csv.csv Complete · 3d ago	0.79892	\otimes	Complete · 4d ago	0.6	9394	•	Complete · 2d ago	0.78933	
⊘	submission.csv Complete · 2d ago · Delete Cabin number Using Xç		79424	submission1.csv Complete · 3d ago	0.6	9394	\otimes	submission.csv Complete · 2d ago	0.80313	
Ø	submission.csv Complete · 2d ago · Index change and Using pycar		78887	submission2.csv Complete · 3d ago	0.6	9394	0	Submission.csv Complete · 3d ago	0.79939	.68178
0	submission.csv Complete · 2d ago · Using pycaret knn		0	submission1.csv Complete · 4d ago	0.6	∅	Complete · 4d ag	Spaceship_Titanic_Se	og.oov	0
0	submission.csv Complete · 3d ago · Using Xgboost	0.	79074			0		Spaceship_Titanic_Se	ong.csv 0	.53776
\otimes	submission.csv Complete · 4d ago · Using Xgboost	0.	79027			⊘	submission_	Spaceship_Titanic_Se	ong.csv 0	.56511

모델 소개 - SVC

```
In [8]:
           svc = SVC()
           clf = GridSearchCV(svc, param_grid,n_jobs=-1,verbose=2)
           clf.fit(X_train, y_train)
         Fitting 5 folds for each of 18 candidates, totalling 90 fits
Out[8]: GridSearchCV(estimator=SVC(), n_jobs=-1,
                      param_grid={'C': [1.0, 10.0, 100.0], 'degree': [1, 2, 3],
                                   'gamma': ['scale'], 'kernel': ['rbf', 'sigmoid'],
                                   'max_iter': [-1], 'tol': [1e-05]},
                      verbose=2)
In [13]:
           clf.best_params_
Out [13]: {'C': 1.0,
          'degree': 1.
          'gamma': 'scale',
           'kernel': 'rbf',
          'max_iter': -1,
          'tol': 1e-05}
```



모델 소개 - LightGBM

```
M from hyperopt import fmin, tpe. Trials
  trials = Trials()
   # fmin()함수를 호출. max_evals지정된 횟수만큼 반복 후 목적함수의 최소값을 가지는 최적 입력값 추출.
                                                                                                                   | Igbm_clf = LGBMClassifier(n_estimators=800, num_leaves=int(best['num_leaves']),
   best = fmin(fn=objective_func, space=lgbm_search_space, algo=tpe.suggest,
                                                                                                                                               max_depth=int(best['max_depth']),
              max_evals=100, # 최대 반복 횟수를 지정합니다.
                                                                                                                                               min_child_samples=int(best['min_child_samples']),
              trials=trials, rstate=np.random.default_rng(seed=30))
                                                                                                                                               subsample=round(best['subsample'], 5),
                                                                                                                                               learning rate=round(best['learning rate'], 5))
   print('최적 파라미터 :', best)
                                                                                                                      # evaluation metric을 accuracy로, early stopping은 500으로 설정하고 학습 수행
          training's binary logloss: 0.274758
                                                  valid 1's binary logloss: 0.387014
                                                                                                                      lgbm_clf.fit(X_tr, v_tr, early_stopping_rounds=500.
          training's binary_logloss: 0.274411
                                                  valid_1's binary_logloss: 0.386987
                                                                                                                                  eval_metric="accuracy", eval_set=[(X_tr, y_tr), (X_val, y_val)])
          training's binary_logloss: 0.274156
                                                  valid_1's binary_logloss: 0.387044
          training's binary_logloss: 0.273796
                                                  valid_1's binary_logloss: 0.387065
                                                                                                                      # 검증 데이터 예측 및 정확도 계산
          training's binary logloss: 0.273478
                                                  valid 1's binary logloss: 0.387127
                                                                                                                      v pred = labm clf.predict(X test)
                                                  valid 1's binary logloss: 0.387187
          training's binary logloss: 0.273121
                                                                                                                      accuracy = accuracy_score(v_test, v_pred)
          training's binary logloss: 0.272743
                                                  valid 1's binary logloss: 0.387224
                                                                                                                      print("정확도: {0:.4f}".format(accuracy))
          training's binary logloss: 0.272344
                                                  valid 1's binary logloss: 0.387243
   [262]
                                                  valid_1's binary_logloss: 0.387069
          training's binary_logloss: 0.271957
                                                                                                                             training's binary logloss: 0.117452
                                                                                                                                                                    valid 1's binary logloss: 0.445968
          training's binary_logloss: 0.271571
                                                  valid 1's binary logloss: 0.387153
                                                                                                                             training's binary_logloss: 0.117284
                                                                                                                                                                    valid 1's binary logloss: 0.446178
   [264]
          training's binary_logloss: 0.271221
                                                  valid_1's binary_logloss: 0.3873
                                                                                                                             training's binary_logloss: 0.117089
                                                                                                                                                                    valid_1's binary_logloss: 0.446254
          training's binary logloss: 0.270876
                                                  valid_1's binary_logloss: 0.387286
                                                                                                                             training's binary_logloss: 0.116936
                                                                                                                                                                    valid_1's binary_logloss: 0.446302
   [266]
          training's binary logloss: 0.270549
                                                  valid 1's binary logloss: 0.387372
                                                                                                                                                                    valid 1's binary logloss: 0.446532
                                                                                                                             training's binary_logloss: 0.116802
          training's binary_logloss: 0.270111
                                                  valid_1's binary_logloss: 0.387183
                                                                                                                             training's binary_logloss: 0.116625
                                                                                                                                                                    valid_1's binary_logloss: 0.446675
          training's binary_logloss: 0.269855
                                                  valid_1's binary_logloss: 0.387192
                                                                                                                             training's binary_logloss: 0.116481
                                                                                                                                                                    valid_1's binary_logloss: 0.446696
          training's binary_logloss: 0.269459
                                                  valid_1's binary_logloss: 0.387181
                                                                                                                      [617]
                                                                                                                             training's binary_logloss: 0.116344
                                                                                                                                                                    valid_1's binary_logloss: 0.446822
                                                    ■ 100/100 [02:46<00:00. 1.67s/trial. best loss: -0.8110440034
                                                                                                                             training's binary_logloss: 0.11621
                                                                                                                                                                    valid_1's binary_logloss: 0.447181
   최적 파라미터 : {'learning rate': 0.04599390207392148, 'max depth': 148.0, 'min child samples': 68.0, 'num leaves
                                                                                                                      [619]
                                                                                                                             training's binary logloss: 0.116063
                                                                                                                                                                    valid 1's binary logloss: 0.447221
   ple': 0.7816996264425102}
                                                                                                                             training's binary logloss: 0.115901
                                                                                                                                                                    valid 1's binary logloss: 0.447216
                                                                                                                                                                    valid_1's binary_logloss: 0.447373
                                                                                                                             training's binary logloss: 0.11576
                                                                                                                             training's binary logloss: 0.115636
                                                                                                                                                                    valid 1's binary logloss: 0.447472
                                                                                                                      [623] training's binary logloss: 0.115496
                                                                                                                                                                    valid 1's binary logloss: 0.447641
                                                                                                                            training's binary logloss: 0.11532
                                                                                                                                                                    valid 1's binary logloss: 0.447865
                                                                                                                      [625] training's binary_logloss: 0.115165
                                                                                                                                                                    valid 1's binary logloss: 0.447997
                                                                                                                             training's binary logloss: 0.114953
                                                                                                                                                                    valid 1's binary logloss: 0.448016
                                                                                                                      [627] training's binary logloss: 0.114788
                                                                                                                                                                    valid 1's binary logloss: 0.448115
                                                                                                                      정확도: 0.8114
```



submission_Spaceship_Titanic_Seong.csv

0.68178

모델 소개 - Xgboost

```
[ ] print(get_score(xgb.XGBClassifier(**params_XGB_best),X,y).mean())
```

0.8110037607924149



submission.csv

모델 소개 - RandomForest

 \odot

submission2.csv

Complete · 15s ago

모델 소개 - KNN

```
from sklearn.model selection import GridSearchCV
|params= {
    'n neighbors' : list(range(1.10)).
    'leaf_size' : list(range(10,40)),
    'weights' : ["uniform", "distance"],
    'metric': ['euclidean', 'manhattan', 'minkowski']
knn = KNeighborsClassifier()
grid clf = GridSearchCV(knn, param grid=params, scoring='accuracy', cv=3)
grid clf.fit(X train, y train)
GridSearchCV(cv=3, error_score=nan,
             estimator=KNeighborsClassifier(algorithm='auto', leaf size=30,
                                            metric='minkowski'.
                                            metric params=None, n iobs=None,
                                            n neighbors=5. p=2.
                                            weights='uniform'),
             n iobs=None.
             param grid={'leaf_size': [10, 11, 12, 13, 14, 15, 16, 17, 18, 19,
                                       20, 21, 22, 23, 24, 25, 26, 27, 28, 29,
                                       30, 31, 32, 33, 34, 35, 36, 37, 38, 39],
                         'metric': ['euclidean', 'manhattan', 'minkowski'],
                         'n neighbors': [1, 2, 3, 4, 5, 6, 7, 8, 9].
                         'weights': ['uniform', 'distance']}.
             pre_dispatch='2*n_jobs', refit=True, return_train_score=False,
             scoring='accuracy', verbose=0)
```

```
grid_clf.best_params_
```

```
{'leaf_size': 10,
'metric': 'euclidean',
'n_neighbors': 9,
'weights': 'uniform'}
```



knn3_submission_csv.csv

감사합니다.